MASTER ESMIHA · SUPPORT DE TRAVAUX DIRIGÉS

Machine learning : corrigé du TD

Validation non croisée, validation croisée, comparaison des modèles et interprétation

Jeu de données
10 variables

5 méthodes
RF · XGB · L1/L2

Validation
10 plis

Interpréter
Scores · courbes

QUENTIN LAMBOLEY · MASTER ESMIHA

Ce corrigé suit les manipulations, de la première exploration jusqu'à la comparaison des algorithmes. Les exemples chiffrés servent à comprendre un raisonnement ; ils ne sont pas des scores à retrouver obligatoirement. La fabrication du jeu de données ne fait pas partie des questions.

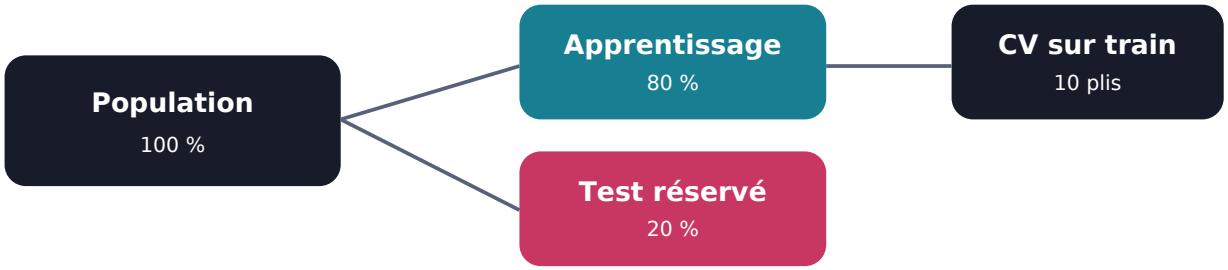
Repère méthodologique

L'objectif n'est pas de deviner toutes les réponses à coup sûr, mais de comprendre comment entraîner un algorithme, vérifier ses erreurs et interpréter son résultat. Les personnages sont fictifs : nous travaillons sur les méthodes, pas sur le réalisme des données.

Comment utiliser ce corrigé

Pour chaque question, je propose d’abord une explication, puis un exemple concret et un point à retenir. Il faut essayer la manipulation dans l’application avant de consulter cette correction. Plusieurs formulations peuvent être justes si le raisonnement est scientifiquement argumenté.

Protocole de référence : jeu de données fictif de 1 000 observations, séparation stratifiée 80/20, puis validation croisée à dix plis dans l’apprentissage. L’effectif, la proportion des classes et la proximité des profils peuvent être modifiés pour étudier leur influence sur l’évaluation. Comparer Random Forest, XGBoost, Ridge, Lasso et Elastic Net. Les réseaux de neurones sont un complément facultatif.



La validation croisée doit avoir lieu à l’intérieur du train. Le jeu de test ne sert pas à choisir le modèle, les variables ou le seuil de décision.

DONNÉES

01 / Quelle variable le modèle doit-il prédire ? Quelles informations utilisera-t-il pour le faire ?

La cible est Vampirisme (0 = humain ; 1 = vampire). Les dix autres colonnes constituent les variables explicatives. Comme la classe est connue dans les exemples d’entraînement, il s’agit d’une classification supervisée. La nature fictive des exemples ne modifie pas cette définition.

> **Exemple concret.** Par exemple, si l'on connaît la température, l'âge et huit autres caractéristiques d'un nouvel individu, le programme doit choisir « humain » ou « vampire » sans connaître la réponse à l'avance.

> **À retenir : La cible est ce que l'on cherche à prévoir ; les prédicteurs sont les informations disponibles pour y parvenir.**

02 / Pourquoi faut-il regarder la proportion des deux classes avant de choisir un indicateur de performance ?

Si 95 % des observations sont humaines, répondre systématiquement « humain » donne 95 % d'accuracy mais ne détecte aucun vampire. La répartition des classes doit guider le choix des métriques et l'interprétation du résultat.

> **Exemple concret.** Imaginons 100 individus, dont 90 humains. Un programme qui répond toujours « humain » obtient 90 bonnes réponses, soit 90 % d'accuracy, mais il manque les 10 vampires. Son score paraît bon alors qu'il est inutile pour reconnaître la classe minoritaire.
>
> **À retenir : Toujours comparer l'accuracy au déséquilibre des classes et à une stratégie très simple, comme prédire la classe majoritaire.**

03 / D'après vous, après avoir modifié le nombre d'individus, la proportion de vampires ou la proximité entre les deux groupes, les performances d'un même algorithme sont-elles identiques ? Comment expliquer les différences ?

Non, les résultats peuvent changer. Avec davantage d'individus, le modèle dispose souvent de plus d'exemples pour apprendre et le test contient davantage de cas, mais une amélioration n'est pas garantie à chaque tirage. En modifiant la proportion des classes, on change aussi la difficulté de certaines métriques. Enfin, lorsque les profils humains et vampires deviennent plus proches, leurs caractéristiques permettent moins facilement de les distinguer. À 100 % de proximité, ces caractéristiques ne renseignent plus sur la classe. Il faut comparer les mêmes méthodes avec une procédure identique et répéter les tirages avant de conclure.

> **Exemple concret.** Sur un jeu composé de 90 % d'humains, une accuracy élevée peut correspondre à de nombreux vampires manqués. La balanced accuracy et la sensibilité révèlent mieux cette limite.
>
> **À retenir : Un score dépend du modèle, des données et du protocole : changer l'échantillon peut modifier le résultat.**

04 / Si les vampires deviennent très rares, pourquoi faut-il examiner la précision des prédictions « Vampire » ?

La précision positive indique la proportion de vrais vampires parmi les individus annoncés vampires. Quand la classe positive devient rare, même un faible taux de faux positifs chez les humains peut produire beaucoup de fausses alertes. La sensibilité peut rester stable alors que la précision diminue. C'est notamment pour cette raison que l'accuracy seule ne permet pas de juger un classifieur sur des classes déséquilibrées.

> **Exemple concret.** Un modèle retrouve 8 vampires sur 10, mais signale aussi 30 humains : sa sensibilité est 80 %, tandis que sa précision positive est 8 / 38, soit environ 21 %.
>
> **À retenir : La précision dépend fortement de la fréquence de la classe positive dans la population évaluée.**

05 / En quoi un petit jeu de test rend-il l’estimation des performances moins stable ?

Un score calculé sur peu de cas peut varier beaucoup dès que quelques individus changent. Par exemple, une erreur supplémentaire fait baisser l’accuracy de cinq points sur 20 observations, mais seulement de 0,2 point sur 500. Cela ne signifie pas qu’un grand jeu de données garantit un bon modèle ; il aide surtout à mesurer plus précisément ses erreurs, si les observations sont représentatives.

> **Exemple concret.** Sur 20 personnes, 18 réponses justes donnent 90 %. Si une personne supplémentaire est mal classée, le score tombe à 85 %.

> **À retenir : Plus un indicateur repose sur peu d’observations, plus il faut être prudent dans son interprétation.**

EXPLORATION

06 / Une variable dont les deux distributions se chevauchent peut-elle suffire à classer parfaitement les individus ?

Non : lorsqu’une même valeur apparaît dans les deux classes, cette seule variable ne permet pas de les distinguer avec certitude. Les modèles multivariés combinent plusieurs indices, parfois faiblement informatifs lorsqu’ils sont considérés isolément.

> **Exemple concret.** Si un humain et un vampire ont tous deux une température de 36,2 °C, la température seule ne permet pas de trancher. En revanche, le modèle peut aussi regarder la longueur des canines, la sensibilité au soleil ou le rythme cardiaque.

> **À retenir : Un indice ambigu pris isolément peut devenir utile lorsqu'il est combiné avec d'autres.**

07 / Qu’apporte un nuage de points coloré par classe par rapport à l’examen séparé de deux histogrammes ?

Il permet d’étudier des combinaisons de deux variables et d’identifier des zones de recouvrement ou de séparation que les graphiques univariés masquent. Il ne représente toutefois qu’une projection d’un problème à dix dimensions.

> **Exemple concret.** Sur les histogrammes, l'âge et la longueur des canines semblent chacun peu discriminants. Sur le nuage de points âge × canines, on peut néanmoins voir un groupe d'individus âgés avec des canines longues plus souvent associés aux vampires.

> **À retenir : Un graphique à deux variables aide à voir des combinaisons, mais ne montre pas les huit autres caractéristiques.**

08 / Pourquoi faut-il examiner les corrélations avant d’interpréter l’importance des variables ?

Des variables corrélées peuvent se remplacer dans un modèle. Les coefficients et les importances individuelles deviennent alors plus difficiles à interpréter. Une corrélation n’établit pas, à elle seule, une relation causale.

> **Exemple concret.** Si la force et la vitesse sont très liées, un modèle peut s'appuyer surtout sur la force, un autre surtout sur la vitesse, sans que leurs prédictions changent beaucoup. Une importance faible ne signifie donc pas nécessairement que la variable n'apporte aucune information.
>
> **À retenir : Des variables corrélées compliquent la lecture des coefficients et des importances ; corrélation ne signifie pas causalité.**

09 / Si une caractéristique distingue assez bien les groupes, pourquoi conserver malgré tout plusieurs prédicteurs ?

Une variable peut être globalement informative et rester ambiguë pour un individu donné. Combiner différentes caractéristiques peut aider à départager les profils difficiles : l’âge apporte une information, mais la température, la longueur des canines ou la sensibilité au soleil peuvent compléter cette information. Il faut ensuite vérifier sur des individus non vus que cette combinaison améliore réellement les prédictions.

> **Exemple concret.** Deux personnages ont la même température, mais des âges et des sensibilités au soleil très différents : le modèle multivarié peut leur attribuer des scores distincts.
>
> **À retenir : Une bonne classification s’appuie souvent sur plusieurs indices complémentaires plutôt que sur une règle unique.**

10 / Que signifie un graphique où les deux classes se mélangent fortement ?

Lorsque les points humains et vampires occupent la même zone, ces deux variables ne permettent pas de les séparer clairement à elles seules. Cela n’implique pas que toute classification soit impossible : d’autres variables ou leurs interactions peuvent contenir de l’information. Inversement, une séparation spectaculaire sur un graphique ne prouve pas qu’elle se maintiendra sur le jeu de test.

> **Exemple concret.** Sur un nuage âge-température, des points des deux couleurs se superposent. Un troisième indice, invisible sur le graphique, peut aider à les distinguer.
>
> **À retenir : Un graphique en deux dimensions ne représente qu’une partie de l’information utilisée par le modèle.**

11 / Pourquoi faut-il éviter d’interpréter une corrélation comme une preuve de causalité ?

Une corrélation signifie que deux variables ont tendance à évoluer ensemble dans cet échantillon. Cela ne démontre pas que modifier l’une ferait changer l’autre : une troisième variable peut expliquer leur association, ou la relation peut être propre au jeu de données simulé. Dans ce TD, les corrélations servent avant tout à explorer les données et à comprendre la redondance des prédicteurs.

> **Exemple concret.** Si l’âge et la longueur des canines sont associés, cela ne démontre pas que vieillir allonge les canines.

> **À retenir : Association statistique et mécanisme causal sont deux choses différentes.**

VALIDATION SIMPLE

12 / Pourquoi sépare-t-on les observations en apprentissage et en test ?

L’apprentissage sert à ajuster les paramètres. Le jeu de test, tenu à l’écart, mesure ensuite les prédictions sur des individus non vus. La séparation stratifiée conserve approximativement la proportion de classes dans chaque ensemble.

> **Exemple concret.** Avec 1 000 individus, on peut en réserver environ 800 pour entraîner les modèles et 200 pour vérifier leurs prédictions. Les 200 individus du test restent inconnus du modèle pendant son apprentissage.

> **À retenir : Le test sert à évaluer sur des observations non vues, pas à apprendre ni à régler continuellement les modèles.**

13 / Comment une forêt aléatoire prend-elle une décision, et pourquoi ne repose-t-elle pas sur un seul arbre ?

La forêt entraîne plusieurs arbres de décision avec de l’aléa dans les données et les variables proposées. Chaque arbre vote pour une classe ; les votes agrégés produisent la prédiction. Cette diversité réduit généralement l’instabilité d’un arbre isolé, sans supprimer tout risque de surapprentissage.

> **Exemple concret.** Un arbre peut classer un individu vampire, un autre humain et un troisième vampire. En regroupant les votes de nombreux arbres construits à partir de données et de variables légèrement différentes, la forêt évite de dépendre d'une seule règle fragile.

> **À retenir : Random Forest combine des arbres diversifiés ; elle ne se contente pas de fabriquer un arbre très grand.**

14 / En quoi XGBoost se distingue-t-il d’une forêt aléatoire ?

Dans une forêt aléatoire, les arbres sont construits avec une forte indépendance et leurs résultats sont agrégés. Dans le boosting, les arbres sont ajoutés successivement pour améliorer la fonction objectif, en corrigeant progressivement les limites de l’ensemble précédent. Les performances dépendent du réglage et des données.

> **Exemple concret.** Dans une forêt, plusieurs arbres sont entraînés de façon relativement indépendante et leur avis est agrégé. Avec XGBoost, le deuxième arbre est construit en tenant compte de ce que le premier ensemble prédit encore mal, puis un troisième poursuit l'amélioration.
>
> **À retenir : Forêt : diversité et agrégation. XGBoost : construction progressive d'un ensemble d'arbres.**

15 / Que pénalise Ridge et pourquoi cela peut-il améliorer la généralisation ?

Ridge ajoute une pénalisation L2, liée à la somme des carrés des coefficients. Elle tend à réduire leur amplitude, ce qui limite les ajustements excessifs aux particularités de l’échantillon. Dans ce TD, Ridge correspond à une régression logistique régularisée.

> **Exemple concret.** Sans régularisation, une régression peut donner un poids excessif à une caractéristique très particulière des 800 individus d'apprentissage. Ridge pousse les coefficients à rester plus modestes, ce qui peut éviter de suivre des fluctuations propres à ce groupe.
>
> **À retenir : Ridge (L2) limite l'amplitude des coefficients ; il ne supprime généralement pas les variables.**

16 / Quelle différence pratique entre Lasso et Ridge pour la sélection des variables ?

Lasso utilise une pénalisation L1, susceptible de rendre certains coefficients exactement nuls : il réalise ainsi une forme de sélection de variables. Ridge réduit plutôt les coefficients sans en annuler habituellement beaucoup. Avec des prédicteurs corrélés, les choix de Lasso peuvent être instables.

> **Exemple concret.** Avec dix variables, un modèle Lasso peut finir par donner un coefficient nul à la force et à la vitesse s'il juge qu'elles n'aident pas suffisamment une fois les autres variables prises en compte. Ridge peut conserver les dix coefficients, tout en les réduisant.
>
> **À retenir : Lasso (L1) peut écarter des prédicteurs ; ce choix peut varier quand plusieurs variables sont très proches.**

17 / Quel est le principe d’Elastic Net ?

Elastic Net associe les pénalisations L1 de Lasso et L2 de Ridge. Ce compromis peut favoriser la parcimonie tout en stabilisant certains choix de variables corrélées. Le résultat dépend notamment de la force de régularisation et de la proportion L1/L2.

> **Exemple concret.** Lasso pourrait retenir seulement l'une de deux caractéristiques très liées, tandis que Ridge les conserverait toutes les deux avec des poids réduits. Elastic Net cherche un compromis entre ces comportements, selon les réglages choisis.
>
> **À retenir : Elastic Net associe L1 et L2 : sélection possible de variables et limitation de coefficients trop grands.**

18 / Pourquoi deux modèles entraînés sur les mêmes individus n’obtiennent-ils pas nécessairement les mêmes prédictions ?

Chaque algorithme représente différemment la relation entre les variables et la classe : fonction linéaire régularisée, combinaison d’arbres ou réseau de neurones. Leurs biais, leur souplesse et leur optimisation diffèrent. Les comparer suppose de conserver les mêmes données et le même protocole.

> **Exemple concret.** Pour un individu proche de la frontière, une forêt peut choisir « vampire » parce que plusieurs arbres votent en ce sens ; une régression logistique peut au contraire calculer un score de 48 % et répondre « humain » au seuil de 50 %.
>
> **À retenir : Il n'existe pas de modèle gagnant par principe : on compare des méthodes différentes dans des conditions identiques.**

19 / Que signifie une accuracy de 0,90 sur les données de test ?

Au seuil retenu, environ 90 % des observations du jeu de test ont reçu la bonne classe. Cela ne dit pas quelles erreurs ont été commises, ni si les classes sont équilibrées, ni si les probabilités annoncées sont fiables. Un test limité comporte aussi une incertitude d’échantillonnage.

> **Exemple concret.** Sur un test de 200 individus, une accuracy de 0,90 correspond à 180 prédictions correctes et 20 erreurs. Mais ces 20 erreurs pourraient concerner surtout des vampires, ce que l'accuracy ne permet pas de savoir.
>
> **À retenir : L'accuracy décrit la proportion de bonnes réponses, pas la nature des erreurs.**

20 / Pourquoi la performance d’apprentissage n’est-elle pas une mesure suffisante de la qualité d’un modèle ?

Un modèle très flexible peut apprendre les particularités du train et obtenir un score d’apprentissage élevé sans généraliser. C’est le surapprentissage. Il faut observer ses résultats sur des observations non utilisées à l’entraînement, et recourir à une validation appropriée pour choisir les réglages.

> **Exemple concret.** Un modèle peut réussir 99 % des prédictions sur les 800 individus qu'il a vus et seulement 75 % sur les 200 inconnus. Il a probablement retenu des particularités de son entraînement qui ne se retrouvent pas ailleurs.
>
> **À retenir : La généralisation se juge sur de nouvelles observations ; un score d'apprentissage élevé ne suffit jamais.**

21 / Pourquoi est-il indispensable de faire apprendre tous les algorithmes sur exactement le même train ?

Pour comparer les méthodes, il faut maintenir constants les éléments qui ne font pas partie de la comparaison : jeu d’apprentissage, jeu de test, définition de la classe positive et métriques. Sinon, une différence de score peut provenir des données plutôt que de l’algorithme. Dans ce TD, les cinq modèles principaux utilisent donc la même séparation stratifiée.

> **Exemple concret.** Comparer une forêt entraînée sur 800 personnes à un XGBoost entraîné sur 400 personnes ne permet pas d’attribuer l’écart de score à la seule méthode.
>
> **À retenir : Une comparaison scientifique modifie un facteur à la fois.**

22 / Comment reconnaître une situation de surapprentissage ?

Un modèle surapprend lorsqu'il s'ajuste aux détails particuliers, voire au bruit, du train, mais prédit moins bien sur de nouvelles observations. Un écart important entre performance d'apprentissage et performance de validation peut être un signal, sans suffire à établir un diagnostic à lui seul. Limiter la complexité, régulariser et utiliser une validation appropriée peuvent aider.

> **Exemple concret.** Un modèle réalise 99 % de bonnes réponses sur l'apprentissage, mais seulement 73 % sur le test : il a peut-être mémorisé des détails non généralisables.

> **À retenir : L'objectif est de généraliser, pas de mémoriser les observations connues.**

23 / Que signifie une probabilité prédite de 0,70 pour un individu ?

Le modèle attribue un score de 70 % à la classe Vampire pour cet individu. Avec un seuil de 0,50, il le classera vampire. Cela ne signifie pas que le résultat est certain ni que les probabilités du modèle sont nécessairement bien calibrées. La calibration se vérifie en comparant les probabilités annoncées à la fréquence observée des classes.

> **Exemple concret.** Sur cent profils évalués à environ 70 %, un modèle bien calibré devrait en retrouver approximativement 70 vampires.

> **À retenir : Une classe prédite résulte d'un seuil ; une probabilité doit être évaluée pour sa fiabilité.**

24 / Pourquoi un algorithme plus complexe n'est-il pas automatiquement plus performant ?

La complexité supplémentaire permet d'apprendre des relations plus variées, mais demande souvent davantage de données et de réglages. Un modèle simple peut être suffisant lorsque l'information est bien représentée par ses hypothèses. Un modèle complexe peut surapprendre. C'est la validation des performances, et non le prestige d'un algorithme, qui doit guider le choix.

> **Exemple concret.** Une régression logistique régularisée peut surpasser un ensemble d'arbres si les classes sont assez bien séparées par une combinaison linéaire des prédicteurs.

> **À retenir : On choisit un modèle pour ses résultats sur des données nouvelles et ses contraintes, pas pour sa sophistication.**

VALIDATION CROISÉE

25 / Décris le principe d'une validation croisée stratifiée à dix blocs.

Le train est découpé en dix plis de compositions de classes proches. Dix modèles sont entraînés : à chaque itération, neuf plis servent à l'apprentissage et le dernier à la validation. Chaque pli joue une fois le rôle de validation. Les dix scores décrivent une performance de validation interne.

> **Exemple concret.** Sur 800 individus d'apprentissage, dix blocs contiennent environ 80 individus chacun. On entraîne sur environ 720 individus et on valide sur 80 ; on répète dix fois en changeant le bloc de validation. Chaque bloc est utilisé une fois pour valider.

> **À retenir : Les dix plis sont créés à l'intérieur du train : les 200 individus du test n'y participent jamais.**

26 / Quel est l’intérêt de la validation croisée par rapport à une seule séparation apprentissage/test ?

La validation croisée répète l’évaluation interne sur plusieurs sous-ensembles. Elle aide à comparer les modèles sans s’appuyer sur une seule répartition et donne une idée de la variabilité entre plis. Elle ne remplace pas une évaluation finale indépendante et n’élimine pas toutes les sources d’incertitude.

> **Exemple concret.** Avec une seule séparation, les individus les plus difficiles peuvent tomber par hasard dans le test. La validation croisée répète la mesure sur dix groupes différents et permet de voir si la méthode fonctionne de façon relativement stable.

> **À retenir : Elle sert à comparer et régler les modèles sur le train ; elle ne remplace pas le test final réservé.**

27 / Pourquoi doit-on standardiser à l’intérieur de chaque pli de validation ?

Si la standardisation utilise les observations de validation avant l’apprentissage, de l’information fuite vers le modèle. Avec un Pipeline, StandardScaler est ajusté exclusivement sur les neuf plis d’apprentissage, puis appliqué au dixième pli. Le même principe s’applique au test final.

> **Exemple concret.** Pour transformer les températures, on calcule une moyenne et un écart-type. Si ces valeurs sont calculées avec les 80 individus du pli de validation, le prétraitement a déjà « regardé » les données censées être inconnues. Le pipeline évite cette fuite.

> **À retenir : Chaque transformation qui apprend des paramètres doit être ajustée sur les données d'entraînement du pli, jamais sur sa validation.**

28 / Comment interpréter la moyenne et l’écart-type des dix scores obtenus ?

La moyenne résume les dix évaluations internes ; l’écart-type indique la dispersion des performances entre les plis. Un écart-type faible suggère une moindre variabilité sur ces partitions, mais ne constitue ni un intervalle de confiance, ni une preuve de robustesse sur d’autres populations.

> **Exemple concret.** Un algorithme obtient 0,90 d'accuracy moyenne sur dix plis. S'il oscille seulement entre 0,89 et 0,91, ses scores sont assez réguliers ; s'il va de 0,65 à 0,99, la même moyenne dissimule une forte variabilité.

> **À retenir : Toujours lire ensemble le score moyen et sa dispersion ; l'écart-type des plis n'est pas un intervalle de confiance.**

29 / Pourquoi ne faut-il pas regarder le test final pour choisir le meilleur algorithme ?

Si l’on essaie de nombreux algorithmes ou réglages et que l’on sélectionne celui qui réussit le mieux sur le test, ce dernier influence indirectement le modèle choisi. Il ne mesure plus une évaluation complètement indépendante. Le protocole recommandé consiste à comparer les candidats au sein du train, notamment par validation croisée, puis à mesurer une fois la performance finale sur le test réservé.

> **Exemple concret.** Après vingt essais sur le même test, le meilleur score peut être en partie le résultat du hasard propre à ce test.

> **À retenir : La validation croisée sert au choix ; le test réservé sert à l’évaluation finale.**

30 / Pourquoi un résultat moyen en validation croisée peut-il masquer un problème ?

Deux modèles peuvent obtenir la même moyenne avec des écarts très différents entre les plis. Une forte dispersion peut signaler que les performances dépendent beaucoup des individus présents dans les blocs. Il faut examiner les scores individuels, la distribution des classes et la taille des plis. Ce constat reste descriptif : les plis ne constituent pas des expériences totalement indépendantes.

> **Exemple concret.** Les scores 0,89-0,91 autour de 0,90 sont beaucoup plus homogènes que des scores allant de 0,65 à 0,99 pour une moyenne comparable.
>
> **À retenir : La moyenne décrit un niveau central ; la variabilité renseigne sur la régularité observée.**

COMPARAISON



31 / Peut-on comparer directement l’accuracy de test et l’accuracy moyenne de validation croisée comme s’il s’agissait de deux répétitions identiques ?

Non. Le test fournit une estimation sur un ensemble réservé, tandis que la validation croisée est calculée exclusivement dans le train après plusieurs réentraînements. Un écart entre ces deux scores est informatif, mais ne signifie pas à lui seul qu’une méthode est erronée. Pour choisir les modèles, privilégier la validation interne et réserver le test à l’évaluation finale.

> **Exemple concret.** Une accuracy moyenne de validation croisée de 0,87 et une accuracy de test de 0,91 ne sont pas deux tirages interchangeables. La première regroupe dix évaluations internes ; la seconde concerne un groupe réservé et un modèle réentraîné sur tout le train.
>
> **À retenir : Les deux scores sont utiles mais ne répondent pas exactement à la même question.**

32 / Pourquoi le modèle qui a la meilleure accuracy n’est-il pas nécessairement le meilleur choix ?

L’accuracy met toutes les erreurs dans le même total et peut masquer une sensibilité insuffisante. Il faut examiner la matrice de confusion, la sensibilité, la spécificité, la précision, l’AUC-ROC et la calibration selon l’objectif, ainsi que la stabilité et l’interprétabilité du modèle.

> **Exemple concret.** Le modèle A identifie 98 % des humains mais seulement 40 % des vampires ; le modèle B reconnaît 90 % de chaque groupe. Selon l'objectif, B peut être préférable même si les deux ont une accuracy globale proche.
>
> **À retenir : Le meilleur choix dépend des erreurs que l'on veut éviter, de la stabilité et de la facilité d'interprétation.**

33 / Quelle différence entre sensibilité et précision positive ?

La sensibilité répond à « Parmi les vrais vampires, combien sont retrouvés ? ». La précision répond à « Parmi les individus annoncés vampires, combien le sont vraiment ? ». Un modèle peut trouver presque tous les vampires tout en déclenchant beaucoup de fausses alertes, et donc avoir une bonne sensibilité avec une faible précision.

> **Exemple concret.** Sur 20 vampires réels, 18 sont trouvés : sensibilité 90 %. Si le modèle annonce 60 vampires au total, la précision est 18 / 60 = 30 %.

> **À retenir : Sensibilité et précision répondent à deux questions différentes ; elles se lisent ensemble.**

34 / Pourquoi l'accuracy peut-elle augmenter alors que le modèle devient moins utile ?

Lorsqu'une classe est très fréquente, prédire majoritairement cette classe augmente mécaniquement le nombre de bonnes réponses globales, sans garantir une détection correcte de la classe rare. Une accuracy supérieure peut ainsi s'accompagner d'une sensibilité plus faible. La balanced accuracy et la matrice de confusion permettent de ne pas masquer cette différence.

> **Exemple concret.** Avec 90 % d'humains, un classifieur « toujours humain » atteint 90 % d'accuracy, mais 0 % de sensibilité pour les vampires.

> **À retenir : Un score global élevé n'est pas forcément adapté à la question posée.**

35 / Dans la matrice de confusion, que signifient un faux positif et un faux négatif ?

Un faux positif est un humain classé vampire ; un faux négatif est un vampire classé humain. La sensibilité mesure la proportion de vampires reconnus (VP / [VP + FN]) et la spécificité celle des humains correctement reconnus (VN / [VN + FP]).

> **Exemple concret.** Si l'on annonce « vampire » pour un humain, c'est un faux positif. Si l'on annonce « humain » pour un vampire, c'est un faux négatif. Sur 20 vrais vampires, si le modèle en retrouve 15, sa sensibilité est de 15/20 = 75 %.

> **À retenir : Lire séparément les faux positifs et les faux négatifs pour comprendre les limites du modèle.**

36 / Que devient généralement la sensibilité lorsque l'on abaisse le seuil de 0,50 à 0,30 ?

À probabilités fixes, abaisser le seuil ne peut pas diminuer la sensibilité : davantage de vrais vampires peuvent être détectés. En contrepartie, la spécificité ne peut pas augmenter : certains humains deviennent faux positifs. Le compromis dépend des conséquences respectives des deux erreurs.

> **Exemple concret.** Un individu reçoit un score vampire de 0,42. Au seuil 0,50 il est classé humain ; au seuil 0,30 il devient vampire. Le modèle n'a pas changé, seule la règle de décision a changé.

> **À retenir : Un seuil plus bas retrouve au moins autant de vrais positifs, mais produit aussi potentiellement plus de faux positifs.**

37 / Quel est l’effet de l’augmentation du seuil de décision ?

Avec un seuil plus élevé, moins d’individus seront annoncés vampires. À scores inchangés, le nombre de faux positifs ne peut pas augmenter, mais le nombre de vampires manqués peut augmenter. La sensibilité ne peut donc pas s’améliorer quand on augmente le seuil. Le bon seuil dépend de l’objectif et doit idéalement être choisi sans utiliser le test final.

> **Exemple concret.** Avec un score de 0,62, un individu est vampire au seuil 0,50 et humain au seuil 0,70.

> **À retenir : Changer le seuil modifie le compromis entre fausses alertes et cas manqués, pas les scores appris.**

38 / Que complètent les courbes ROC et précision-rappel par rapport à l’accuracy ?

La ROC décrit le compromis sensibilité/taux de faux positifs aux différents seuils ; son aire résume la discrimination. La courbe précision-rappel décrit la relation entre la proportion de positifs annoncés correctement et le rappel ; elle est particulièrement informative lorsque la classe positive est rare. Aucune de ces courbes ne démontre la calibration.

> **Exemple concret.** Deux modèles ont 85 % d'accuracy au seuil 0,50. L'un peut pourtant mieux classer les individus lorsqu'on modifie le seuil. Les courbes ROC et précision-rappel montrent ces compromis sur une série de seuils.

> **À retenir : L'accuracy décrit un seuil choisi ; ROC et précision-rappel renseignent sur la discrimination à plusieurs seuils.**

39 / Pourquoi faut-il lire à la fois les courbes ROC et précision-rappel ?

La courbe ROC compare la sensibilité au taux de faux positifs pour différents seuils. La courbe précision-rappel décrit le compromis entre retrouver les vampires et limiter les fausses alertes parmi les vampires annoncés. Lorsque les vampires sont rares, la précision positive peut chuter malgré un taux de faux positifs apparemment faible ; la courbe précision-rappel devient alors particulièrement informative.

> **Exemple concret.** Un modèle peut avoir une bonne AUC-ROC tout en produisant beaucoup de faux positifs relativement au petit nombre de vampires.

> **À retenir : Les courbes répondent à des questions complémentaires et dépendent de l’objectif.**

40 / Pourquoi une bonne AUC-ROC ne garantit-elle pas de bonnes probabilités ?

L’AUC-ROC mesure principalement la qualité de l’ordre des scores entre les classes. Un modèle peut bien classer les individus tout en annonçant des probabilités trop extrêmes ou trop prudentes. La courbe de calibration et le score de Brier évaluent cet autre aspect.

> **Exemple concret.** Si, parmi cent individus auxquels le modèle attribue environ 80 % de probabilité de vampirisme, seuls cinquante sont effectivement vampires, les probabilités sont trop élevées, même si l'ordre des scores entre les individus est bon.

> **À retenir : Bien classer les individus et annoncer des probabilités fiables sont deux qualités distinctes.**

INTERPRÉTATION

41 / Que mesure l’importance d’une variable calculée par permutation ?

On permute les valeurs d’un prédicteur puis on mesure la diminution de performance. Une forte dégradation montre que le modèle exploite l’information portée par cette variable. En présence de redondances, plusieurs variables peuvent se remplacer et sembler individuellement peu importantes.

> **Exemple concret.** On mesure d'abord une accuracy équilibrée de 0,88. On mélange ensuite la longueur des canines entre les individus, sans changer les autres variables. Si le score tombe à 0,72, cette variable est utile à ce modèle pour produire ses prédictions.

> **À retenir : La permutation mesure une perte de performance du modèle, pas une preuve biologique de l'effet d'une variable.**

42 / Si une variable ressort importante pour un modèle, faut-il en conclure qu’elle cause le vampirisme ?

Non. Une forte importance indique que la variable aide le modèle à prédire dans les données étudiées, selon la méthode de calcul. Elle ne démontre pas qu’une intervention sur cette caractéristique changerait la classe réelle. Dans cette simulation, cette distinction est particulièrement évidente : les relations ont été construites pour l’exercice.

> **Exemple concret.** La longueur des canines peut être très utilisée par le classifieur sans qu’on puisse démontrer une relation causale à partir de ce graphique.

> **À retenir : Une variable utile pour prédire n’est pas nécessairement une cause du phénomène étudié.**

43 / Que révèle une courbe de dépendance partielle et pourquoi ne faut-il pas y voir un effet causal ?

La PDP décrit comment varie, en moyenne, la prédiction du modèle lorsque l’on remplace artificiellement une variable par différentes valeurs. Les courbes ICE montrent les réponses des individus. Cette manipulation numérique ne prouve pas qu’un changement réel de la variable provoquerait ce changement de classe.

> **Exemple concret.** Pour la température, on force successivement différentes valeurs et on observe le score calculé par le modèle. La PDP résume la réponse moyenne ; les courbes ICE montrent si les individus réagissent de la même manière.

> **À retenir : Une PDP décrit le comportement du modèle, pas ce qui se passerait si l'on modifiait réellement une personne.**

44 / Pourquoi les courbes ICE peuvent-elles être différentes d’un individu à l’autre ?

Les ICE suivent la prédiction de chaque individu lorsque l’on fait varier une caractéristique, toutes les autres étant maintenues aux valeurs de ce profil. Si le modèle utilise des interactions, la même variation n’aura pas le même effet pour tous. La PDP moyenne ces courbes et peut donc masquer une diversité de réponses individuelles.

> **Exemple concret.** Augmenter artificiellement l’âge peut faire fortement monter le score d’un profil, mais peu changer celui d’un autre dont la température et les canines sont déjà très différentes.
>
> **À retenir : La moyenne d’un effet peut cacher des réactions individuelles hétérogènes.**

45 / Pourquoi la carte de décision en deux dimensions n’est-elle qu’une vue partielle du modèle ?

La carte fait varier deux caractéristiques et fixe les huit autres à une valeur de référence, ici la médiane du train. Elle n’est donc qu’une coupe de la fonction de prédiction à dix dimensions, pas une représentation exhaustive de toutes ses frontières.

> **Exemple concret.** Une carte âge × température peut placer un individu dans une zone « vampire », mais un autre individu du même âge et de la même température peut être classé humain à cause de ses huit autres caractéristiques.
>
> **À retenir : La carte 2D est une coupe informative de la décision, et non un résumé complet d'un modèle à dix variables.**

DÉFI

46 / Pourquoi un modèle peut-il annoncer une probabilité de 90 % et se tromper ?

Même bien calibrée, une probabilité de 90 % correspond à une incertitude résiduelle. De plus, une prédiction peut être mal calibrée, et des profils humains et vampires peuvent se chevaucher. C’est précisément pourquoi il faut analyser les erreurs et les probabilités sur un ensemble de cas.

> **Exemple concret.** Une probabilité de 90 % ne veut pas dire « certitude ». Même si les probabilités sont parfaitement calibrées, parmi cent cas estimés à 90 %, on s'attend en moyenne à environ dix cas négatifs.
>
> **À retenir : Une probabilité décrit un degré d'incertitude ; une prédiction individuelle peut donc être fausse.**

PRÉDICTION

47 / Si ton pronostic et celui de la machine diffèrent, comment analyser ce désaccord ?

Il faut distinguer la classe réelle (révélée après le pronostic), le score du modèle et la règle de seuil. Un désaccord peut venir d'une intuition fondée sur une seule variable, alors que le modèle en combine dix, mais le modèle peut aussi se tromper. L'intérêt pédagogique est d'expliciter les indices, l'incertitude et les erreurs plutôt que de considérer la machine comme une autorité.

> **Exemple concret.** Tu annonces humain en te fiant à la température ; le modèle annonce vampire avec 0,54. Sa décision est proche du seuil et donc moins tranchée qu'un score de 0,98.
>
> **À retenir : Une prédiction argumentée doit toujours rester révisable face aux données.**

CONCLUSION

48 / Quel protocole retiendrais-tu pour sélectionner un algorithme sans suradapter ton choix au jeu de test ?

Je commencerais par définir la cible et les métriques, puis par réserver un jeu de test stratifié. Je comparerais les modèles et, au besoin, leurs hyperparamètres par validation croisée sur le seul train, avec le prétraitement inclus dans les pipelines. Je fixerais le modèle et le seuil avant une évaluation finale sur le test réservé, puis je discuterais les biais et limites des données fictives.

> **Exemple concret.** Je réserve d'abord 20 % du jeu de données. Sur les 80 % restants, je teste mes cinq algorithmes et, si nécessaire, plusieurs réglages par validation croisée. Je retiens une méthode selon les indicateurs choisis avant de consulter une seule fois la performance finale sur le test.
>
> **À retenir : Définir la question et les métriques, réserver le test, comparer sur le train, puis conclure sans retoucher son choix sur le test.**

49 / Quelles informations minimales faut-il donner pour que quelqu'un puisse reproduire ton analyse ?

Il faut préciser l'effectif, la répartition des classes, la cible et les prédicteurs, les éventuelles transformations, les critères de sélection, les conditions de répétition des tirages, les proportions train/test, la méthode de validation croisée, les réglages essentiels du modèle, les métriques et les limites. Avec ces éléments, une autre personne peut comprendre le protocole et tenter de retrouver les résultats.

> **Exemple concret.** Dire « Random Forest atteint 91 % » ne permet pas de reproduire l'étude ; donner les données, les divisions, les paramètres et les définitions des scores est beaucoup plus informatif.
>
> **À retenir : Un résultat scientifique s'accompagne de la description de la manière dont il a été obtenu.**

RÉSEAUX DE NEURONES : COMPLÉMENT



50 / Qu’appelle-t-on un neurone artificiel dans ce TD ?

Un neurone artificiel combine plusieurs entrées numériques avec des poids, ajoute un biais, puis applique une fonction d’activation. Il ne fonctionne pas comme un cerveau biologique : c’est une opération mathématique. En reliant beaucoup de ces unités, un réseau peut construire progressivement des représentations utiles pour reconnaître une classe.

> **Exemple concret.** Un neurone reçoit l’âge et la température ; il leur attribue des coefficients différents, ajoute un biais et transmet un nombre à la couche suivante.

> **À retenir : Un neurone artificiel est une petite transformation calculée à partir des données.**

51 / À quoi servent les couches cachées entre les dix variables et la décision finale ?

Les couches cachées permettent au réseau de transformer les informations d’entrée en représentations intermédiaires. Grâce aux fonctions d’activation non linéaires, plusieurs couches peuvent apprendre des associations qui ne se résument pas à une somme de coefficients. Cela ne rend pas automatiquement la prédiction meilleure : il faut que la complexité corresponde aux données.

> **Exemple concret.** Une première couche combine âge et température, une autre réutilise ce résultat avec la sensibilité au soleil pour ajuster le score final.

> **À retenir : Les couches construisent des combinaisons de caractéristiques ; leur nombre n’est pas une garantie de qualité.**

52 / Que change une fonction d’activation comme ReLU ?

ReLU renvoie zéro pour une entrée négative et conserve les valeurs positives. En introduisant une non-linéarité, elle permet au réseau d’apprendre des relations plus variées que l’empilement de simples transformations linéaires. Elle est fréquemment utilisée dans les couches cachées ; la probabilité finale nécessite un traitement adapté à la classification.

> **Exemple concret.** Si un neurone calcule -2, ReLU transmet 0 ; s’il calcule 3, ReLU transmet 3.

> **À retenir : Les activations rendent le réseau plus expressif, mais les effets doivent être vérifiés sur des données nouvelles.**

53 / Pourquoi standardise-t-on les dix variables avant d'entraîner le réseau ?

Lorsque les variables ont des échelles très différentes, leurs amplitudes peuvent perturber ou ralentir l'optimisation. La standardisation transforme généralement chaque variable pour la centrer et l'amener à une échelle comparable. Elle est apprise uniquement sur les données d'entraînement pour éviter une fuite d'information vers la validation ou le test.

> **Exemple concret.** L'âge peut varier sur plusieurs centaines d'années fictives alors que la température varie de quelques degrés : le réseau doit pouvoir traiter les deux sans que leur seule unité domine l'apprentissage.
>
> **À retenir : La standardisation facilite l'optimisation ; elle doit être calculée sans regarder le jeu de test.**

54 / Qu'apprend réellement le réseau pendant l'entraînement ?

À chaque itération, le réseau produit des prédictions, calcule une fonction de perte mesurant leur écart aux réponses attendues et ajuste ses poids pour réduire cette perte. La rétropropagation calcule comment chaque poids contribue à l'erreur, puis un algorithme d'optimisation effectue les mises à jour. Cela reste un apprentissage sur les exemples connus, pas une preuve de généralisation.

> **Exemple concret.** Si plusieurs vampires sont classés humains, certains poids peuvent être modifiés pour rendre ces erreurs moins probables aux itérations suivantes.
>
> **À retenir : Apprendre signifie optimiser des paramètres à partir des erreurs observées sur le train.**

55 / Une courbe de perte qui diminue signifie-t-elle que le réseau sera performant sur des personnes inconnues ?

Non. Une perte d'entraînement décroissante indique que l'algorithme optimise progressivement son objectif sur les exemples utilisés pour apprendre. Elle ne renseigne pas directement sur la performance sur des individus nouveaux. Si le réseau mémorise trop les particularités du train, la perte peut continuer à diminuer alors que la généralisation se dégrade.

> **Exemple concret.** La perte du train passe de 0,6 à 0,1, mais l'accuracy sur les personnes du test stagne : l'amélioration de l'optimisation ne se traduit pas nécessairement par une meilleure prédiction.
>
> **À retenir : Une belle courbe d'apprentissage ne remplace jamais une évaluation indépendante.**

56 / Comment un réseau de neurones se distingue-t-il des méthodes principales du TD, et un réseau plus profond est-il forcément meilleur ?

Un perceptron multicouche apprend des combinaisons de variables par couches de neurones reliées par des poids ajustés. Une activation non linéaire lui permet de représenter des relations souples. Davantage de couches ne garantit pas un meilleur score et peut compliquer l'optimisation ou augmenter le surapprentissage. Il se compare à la forêt et aux régressions logistiques avec le même protocole de validation.

> **Exemple concret.** Un réseau apprend en ajustant les poids de liaisons entre neurones. Un petit réseau peut suffire si les relations sont simples ; un réseau plus profond demande souvent davantage de réglages et peut davantage s'adapter au bruit. Seules les performances en validation permettent de trancher.
>
> **À retenir : La complexité d'un réseau ne garantit ni une meilleure précision ni une meilleure généralisation.**

57 / Pourquoi un réseau profond peut-il être moins bon qu'un réseau compact ?

Un réseau profond offre plus de paramètres et peut représenter des relations complexes, mais il est aussi plus exigeant en calcul, plus sensible aux réglages et susceptible de s'ajuster à des fluctuations propres au train. Sur un exercice comportant seulement dix prédicteurs, une petite architecture peut être tout à fait suffisante. Il faut comparer les deux réseaux selon le même protocole, idéalement en validation croisée.

> **Exemple concret.** Le réseau profond obtient 95 % sur le train et 79 % sur le test, tandis que le compact obtient 89 % et 86 % : la seconde architecture généralise ici mieux.
>
> **À retenir : La performance observée compte davantage que le nombre de couches.**

58 / En quoi un réseau de neurones diffère-t-il d'une forêt aléatoire ou d'une régression logistique ?

La régression logistique combine les variables dans un modèle paramétrique relativement simple ; la forêt aléatoire agrège des arbres de décision ; le réseau de neurones compose des transformations successives dont les poids sont appris par optimisation. Ces méthodes n'ont ni les mêmes hypothèses ni les mêmes exigences en données et en réglages. Aucune n'est systématiquement supérieure.

> **Exemple concret.** Pour le même jeu humain/vampire, une forêt peut exploiter des seuils complexes, un réseau des interactions continues et une régression logistique une séparation simple et régularisée.
>
> **À retenir : Le réseau de neurones est une famille supplémentaire à comparer, pas le but principal du TD.**

Formules et repères pour interpréter les scores

Indicateur	Calcul	Interprétation
Accuracy	(VP + VN) / (VP + VN + FP + FN)	Proportion totale des décisions correctes.
Sensibilité	VP / (VP + FN)	Parmi les vampires, proportion reconnue.
Spécificité	VN / (VN + FP)	Parmi les humains, proportion reconnue.
Précision positive	VP / (VP + FP)	Parmi les profils annoncés vampires, proportion réellement vampire.
Balanced accuracy	(sensibilité + spécificité) / 2	Moyenne des performances sur les deux classes.
F1-score	2 × précision × sensibilité / (précision + sensibilité)	Équilibre précision/rappel au seuil retenu.
Score de Brier	Moyenne de (probabilité - cible)²	Plus faible = mieux ; dépend aussi de la prévalence.
AUC-ROC	Aire sous la courbe ROC	Capacité à classer les deux classes sur les seuils possibles.

VP : vrai positif. VN : vrai négatif. FP : faux positif. FN : faux négatif. Dans ce TD, « Vampire » est la classe positive.

Pour refaire le TD à domicile

1. Décompresser le dossier du TD. 2. Installer Python 3.11 ou 3.12 si nécessaire. 3. Exécuter le lanceur Windows, Linux ou macOS. 4. Attendre la première installation des dépendances, puis ouvrir l’adresse locale indiquée. 5. Reproduire les manipulations en utilisant les boutons de progression et conserver ses réponses dans le carnet. Les lancements suivants peuvent fonctionner sans connexion une fois toutes les dépendances installées.

À conserver dans le compte rendu : effectif et répartition des classes, prédicteurs utilisés, protocole train/test, algorithmes comparés, nombre de plis, scores et leurs limites, matrice de confusion, interprétation des variables et conclusions.

Quentin Lamboley · Master ESMIHA · Support de travaux dirigés